



UNIVERSIDAD DE CONCEPCIÓN

FACULTAD DE INGENIERÍA

DEPARTAMENTO DE INGENIERÍA INFORMÁTICA

Informe tarea

Escape de la torre

Nombre:

Leonardo Guerrero

Matricula:

2024047370

Asignatura: Inteligencia Artificial

Profesor: Julio Godoy

Fecha: 28 de septiembre de 2026

Índice

1. Introducción	2
2. Descripción del problema y cumplimiento del enunciado	3
2.1. Restricciones consideradas	3
2.2. Correspondencia entre el enunciado y el código	3
3. Metodología de la solución	4
3.1. Modelo formal del entorno	4
3.2. Congestión, capacidad y espera	4
3.3. Propagación del fuego	4
3.4. Protocolo experimental	5
3.5. Definición de las métricas	5
4. Algoritmos implementados	6
4.1. Búsqueda no informada	6
4.1.1. Búsqueda en anchura (BFS)	6
4.1.2. Búsqueda en profundidad (DFS)	6
4.2. Búsqueda informada	6
4.2.1. A^*	6
4.2.2. IDA*	7
4.3. Optimización bioinspirada: algoritmo genético	7
5. Implementación de interfaz y herramientas auxiliares	7
6. Resultados experimentales	8
6.1. Resultados con propagación cada tres turnos ($k = 3$)	8
6.2. Resultados con propagación cada cuatro turnos ($k = 4$)	9
6.3. Comparación entre $k = 3$ y $k = 4$	9
6.4. Visualización de resultados	10
6.5. Discusión	11
7. Limitaciones y mejoras	12
8. Conclusión	13
9. Declaración de uso de IA generativa y procedencia	14
10. GitHub	14

1. Introducción

La planificación de trayectorias en ambientes dinámicos constituye un problema central de la Inteligencia Artificial. En una evacuación, encontrar geoméricamente un camino hasta la salida no es suficiente: los agentes deben desplazarse por una infraestructura parcialmente bloqueada, evitar zonas que se incendian, resolver conflictos de ocupación y reaccionar ante decisiones tomadas por otros agentes. Por ello, el problema combina búsqueda en grafos, planificación bajo incertidumbre y coordinación descentralizada.

El escenario representa un edificio mediante una grilla bidimensional por piso. En cada piso existe una única salida de evacuación y un grupo de personas liderado por Sebastián. El incendio avanza a intervalos discretos, las celdas consumidas se vuelven intransitables y los agentes que no alcanzan la salida antes de ser alcanzados por las llamas se consideran bajas. Además, los pasillos tienen capacidad finita: cuando demasiadas personas intentan utilizar una misma celda, se produce congestión y algunos agentes deben esperar.

El objetivo del trabajo es implementar y comparar los tres paradigmas exigidos:

1. **Búsqueda no informada:** BFS y DFS.
2. **Búsqueda informada:** A* e IDA*, guiados por una heurística admisible.
3. **Optimización bioinspirada:** un algoritmo genético para planificar secuencias de acciones.

La comparación se realizó sobre tres mapas de 50 por 50 celdas: Cuello de Botella, Laberinto Corporativo y Dispersión Abierta. Se analizaron dos frecuencias de propagación del fuego, $k = 3$ y $k = 4$, mediante 200 simulaciones por combinación. Las métricas principales son la tasa de supervivencia y los estadísticos descriptivos de los turnos de despeje.

2. Descripción del problema y cumplimiento del enunciado

2.1. Restricciones consideradas

El sistema satisface las restricciones principales del problema:

- La representación espacial es una grilla regular de filas y columnas.
- Los movimientos planificados son ortogonales: arriba, abajo, izquierda y derecha.
- El algoritmo genético incorpora también la acción de esperar $(0, 0)$.
- Cada celda posee una capacidad física finita y un costo dependiente de su ocupación.
- El fuego se propaga cada k turnos y convierte las celdas alcanzadas en obstáculos permanentes.
- Los agentes pueden replanificar cuando su ruta se vuelve inválida.
- La salida es única por mapa y la evacuación se registra cuando un agente llega a ella.

El análisis se centra en la supervivencia y en los turnos de simulación. No se utiliza el tiempo de CPU como métrica principal, por lo que las tablas y figuras no permiten comparar directamente el tiempo de ejecución computacional de los algoritmos.

2.2. Correspondencia entre el enunciado y el código

La clase **GestorDeEventos** funciona como motor de la simulación. En cada turno incrementa el reloj, mezcla aleatoriamente el orden de los agentes activos, solicita a cada agente que se mueva y, cuando corresponde, propaga el fuego.

La clase **Agente** mantiene la posición actual, la posición anterior, el estado de evacuación, el estado de fallecimiento, la ruta planeada y el estado necesario para replanificar. Antes de moverse verifica si está en fuego o en la salida. Luego valida la ruta almacenada; si el siguiente paso dejó de ser transitable, vuelve a buscar. Si una celda se encuentra saturada según la restricción de capacidad, el agente espera.

La clase **Casilla** representa el tipo de celda y la lista de agentes presentes. El lector interpreta los símbolos definidos por el formato del mapa, mientras que el utilitario de conversión permite transformar una imagen PNG en un archivo textual utilizable por el simulador.

3. Metodología de la solución

3.1. Modelo formal del entorno

Sea $M \in \mathbb{R}^{F \times C}$ una grilla de F filas y C columnas. Cada posición contiene una casilla cuyo tipo puede ser camino, muro o fuego; la salida se almacena como una coordenada objetivo S . Los estados muro y fuego son intransitables.

El grafo implícito del mapa se define como

$$G = (V, E), \quad (1)$$

donde V contiene las celdas transitables y $(u, v) \in E$ si u y v son vecinas ortogonales. Este grafo cambia durante la simulación porque una celda de camino puede transformarse irreversiblemente en fuego.

3.2. Congestión, capacidad y espera

Para una celda destino ocupada por n agentes, se utiliza la función cuadrática:

$$C(n) = 1 + n^2. \quad (2)$$

La capacidad física implementada es:

$$k_{\text{cap}} = 6. \quad (3)$$

La capacidad y el costo cumplen funciones relacionadas, pero no idénticas. La capacidad impone una restricción durante el movimiento, mientras que el costo cuadrático permite que las búsquedas que consideran costos prefieran, cuando existen alternativas, celdas menos ocupadas.

En el caso del algoritmo genético, el mecanismo de respaldo basado en memoria evita preferentemente celdas que ya han sido visitadas muchas veces, pero no convierte toda celda ocupada en una posición prohibida. La memoria registra las visitas de manera acotada y se consulta solamente durante la selección del movimiento de respaldo del algoritmo genético.

3.3. Propagación del fuego

El origen del fuego se selecciona de manera completamente aleatoria, aunque se evita que aparezca en las últimas filas, dado que en los mapas la salida siempre se encuentra en el borde inferior. Esto permite evitar que el fuego aparezca demasiado cerca de la salida y afecte de manera directa el análisis de los resultados. Por otro lado, tampoco se seleccionan como origen las casillas ocupadas por los agentes ni sus casillas vecinas, por la misma razón.

La propagación ordinaria del fuego utiliza probabilidad

$$p = 0.75 \quad (4)$$

y ocurre cada k turnos.

En las ejecuciones del benchmark por consola, cuando el fuego encuentra un muro puede intentar propagarse al otro lado. Si el grosor del muro es d , la probabilidad aplicada es

$$P_{\text{pared}}(d) = p_{\text{pared}}^d, \quad (5)$$

con el valor predeterminado

$$p_{\text{pared}} = 0.25. \quad (6)$$

Por lo tanto, el espesor del muro modifica la probabilidad efectiva de atravesarlo. Este parámetro debe quedar registrado junto con el resto de las condiciones experimentales para facilitar la reproducción de los resultados.

Las celdas alcanzadas por el fuego dejan de ser transitables y los agentes presentes en ellas son registrados como bajas. La salida no se incendia.

3.4. Protocolo experimental

Se realizaron 200 simulaciones independientes por cada combinación de mapa, algoritmo y frecuencia de propagación. Esto permite superar tanto el mínimo de 80 iteraciones como la referencia de 200 ejecuciones indicada para el experimento.

No se fijó una semilla global de aleatoriedad. En consecuencia, pueden variar entre ejecuciones el foco inicial del incendio, el orden de actuación de los agentes y la expansión del fuego. Para facilitar la comparación entre futuras ejecuciones, también es necesario registrar los parámetros completos del fuego, incluida la probabilidad de atravesar paredes.

3.5. Definición de las métricas

La tasa de supervivencia calculada por el benchmark es

$$\text{Supervivencia} = \frac{N_{\text{evacuados}}}{N_{\text{total}}} \times 100. \quad (7)$$

En consecuencia, un agente se contabiliza como superviviente cuando alcanza la salida.

El tiempo de despeje utilizado por la implementación corresponde al turno de evacuación más tardío entre los agentes que sí evacuaron. Si una ejecución no registra evacuaciones, el tiempo de despeje no queda definido. Por esta razón, el benchmark informa adicionalmente el número de corridas con tiempo definido.

Las estadísticas de turnos reportadas corresponden a la media, desviación estándar, mínimo y máximo de las corridas que producen un tiempo definido. Esta métrica debe distinguirse del tiempo de ejecución computacional: los turnos representan tiempo dentro de la simulación, no segundos de CPU.

4. Algoritmos implementados

4.1. Búsqueda no informada

4.1.1. Búsqueda en anchura (BFS)

BFS comienza en la posición del agente y explora los estados por niveles de profundidad. La cola FIFO garantiza que los estados se procesen en orden no decreciente de profundidad. El registro de padres permite reconstruir la trayectoria al alcanzar la salida.

En un grafo no ponderado, BFS es completo y encuentra una ruta con el menor número de movimientos si existe. No obstante, no incorpora directamente la congestión ni la evolución futura del fuego en su función de prioridad.

4.1.2. Búsqueda en profundidad (DFS)

DFS utiliza una pila LIFO y profundiza en una rama antes de retroceder. El conjunto de visitados evita ciclos infinitos, pero no evita que la primera rama elegida sea poco conveniente.

DFS no garantiza una trayectoria mínima y puede producir recorridos largos. En este proyecto, el orden de vecinos influye en la trayectoria obtenida y una trayectoria prolongada puede aumentar la exposición al fuego y la congestión.

4.2. Búsqueda informada

Ambos algoritmos informados reciben una función heurística basada en distancia Manhattan:

$$h(a, b) = |f_a - f_b| + |c_a - c_b|. \quad (8)$$

Como los movimientos son ortogonales, la distancia Manhattan no supera el número mínimo de pasos restantes en un mapa sin obstáculos. Además, la función de congestión satisface $C(n) \geq 1$, por lo que Manhattan constituye una cota inferior del costo de desplazamiento cuando los costos de las celdas son no negativos.

La heurística no predice la propagación futura del incendio ni las decisiones de los demás agentes.

4.2.1. A*

A* combina el costo acumulado y la estimación restante:

$$f(n) = g(n) + h(n). \quad (9)$$

Para un vecino n' se calcula

$$g(n') = g(n) + C(n'). \quad (10)$$

La implementación actualiza el costo conocido y el padre cuando encuentra una alternativa de menor costo, utilizando una cola de prioridad. Al alcanzar la salida se reconstruye la secuencia de coordenadas.

En la simulación, A* puede ejecutarse nuevamente cuando la ruta almacenada deja de ser válida. Por tanto, la planificación es reactiva y utiliza el estado de ocupación disponible en el momento de cada búsqueda.

4.2.2. IDA*

IDA* combina la exploración en profundidad con umbrales sucesivos de A*. Inicialmente utiliza un umbral basado en $h(\text{inicio})$. La búsqueda recursiva poda ramas cuyo valor $f(n)$ supera el umbral y utiliza el menor valor excedido para definir el siguiente umbral.

La implementación conserva, dentro de cada búsqueda, el mejor costo conocido para los estados visitados y evita repetir posiciones ya presentes en la ruta actual.

Para limitar búsquedas prolongadas, cada llamada a IDA* tiene un presupuesto máximo de 500 nodos expandidos. La implementación también registra cuándo se alcanza este límite. Esta restricción controla el costo de una llamada, pero puede impedir encontrar una ruta si la exploración necesaria supera el presupuesto.

4.3. Optimización bioinspirada: algoritmo genético

El algoritmo genético representa una trayectoria como un cromosoma de acciones. Cada gen corresponde a un desplazamiento ortogonal o a la acción de esperar.

La población inicial utiliza información de distancia Manhattan para favorecer, con cierta probabilidad, acciones que acerquen al objetivo, combinándolas con acciones aleatorias. Cada individuo es evaluado mediante una función de fitness que considera costos de congestión y penalizaciones asociadas a movimientos inválidos o a no alcanzar la salida.

Posteriormente se seleccionan individuos, se realiza cruce de un punto y se aplica mutación. La mutación sustituye el gen seleccionado por una acción distinta, evitando mutaciones que no alteren el cromosoma. Además, se conserva la mejor ruta factible encontrada durante la evolución.

Cuando el algoritmo genético no obtiene una ruta factible, el agente utiliza un movimiento de respaldo guiado por una memoria dispersa de las celdas visitadas. El conteo de visitas por celda está acotado y, al elegir un vecino, se priorizan los menos visitados; los empates favorecen evitar el retroceso inmediato y acercarse a la salida. Este mecanismo se habilita solamente para el algoritmo genético.

El algoritmo genético no garantiza encontrar una trayectoria óptima ni una solución en un tiempo determinado. Además, su función de evaluación constituye una aproximación del entorno, ya que durante la evolución de un cromosoma no se reproduce completamente la evolución futura del fuego y la interacción simultánea entre agentes.

5. Implementación de interfaz y herramientas auxiliares

La interfaz opcional se implementó con Pygame y permite visualizar el estado de la simulación. El benchmark de consola es el mecanismo utilizado para generar las estadísticas presentadas en este informe.

El conversor de PNG a texto utiliza colores codificados para representar camino, muro, agente y salida. Posteriormente, el lector de mapas transforma el archivo textual en objetos del dominio. Esta separación permite modificar la topología sin alterar directamente los algoritmos de búsqueda.

6. Resultados experimentales

El benchmark se realizó utilizando 200 simulaciones por combinación de mapa, algoritmo y frecuencia de propagación del fuego. A diferencia de la configuración anterior, los agentes comienzan ahora desde un mismo punto de partida, por lo que los resultados reflejan además el efecto de la congestión y de la competencia por las rutas de evacuación desde una posición inicial común. Para el algoritmo genético se utilizó una población de 40 individuos y 10 generaciones.

6.1. Resultados con propagación cada tres turnos ($k = 3$)

Cuadro 1: Resultados del benchmark con $k = 3$. “Def.” corresponde a corridas con tiempo de despeje definido.

Mapa	Alg.	Sup. (%)	Media	DE	Mín.	Máx.
Cuello	BFS	84.50	53.14	1.30	53	69
	DFS	11.00	149.36	4.29	135	151
	A*	79.50	53.30	2.00	53	71
	IDA*	69.00	62.67	1.75	53	63
	Genético	55.00	82.25	4.75	72	97
Laberinto	BFS	69.50	58.00	0.00	58	58
	DFS	0.00	—	—	—	—
	A*	72.00	58.32	1.87	58	74
	IDA*	38.00	86.55	4.79	86	128
	Genético	1.50	103.33	31.84	72	147
Dispersión	BFS	84.00	49.24	1.80	49	67
	DFS	0.00	—	—	—	—
	A*	78.50	49.06	0.42	49	53
	IDA*	84.00	49.11	0.76	49	57
	Genético	80.00	55.80	2.77	50	63

Corridas con tiempo definido: Cuello: 169/200, 22/200, 159/200, 138/200 y 110/200; Laberinto: 139/200, 0/200, 144/200, 76/200 y 3/200; Dispersión: 168/200, 0/200, 157/200, 168/200 y 160/200.

Con $k = 3$, BFS y A* mantienen un comportamiento relativamente consistente en los tres mapas, aunque sus tasas de supervivencia disminuyen en Laberinto Corporativo respecto de Dispersión Abierta y Cuello de Botella. En Cuello de Botella, BFS alcanza 84.50 % de supervivencia con una media de 53.14 turnos, mientras que A* alcanza 79.50 % con 53.30 turnos. En Laberinto Corporativo, las tasas son de 69.50 % y 72.00 %, respectivamente, con medias cercanas a 58 turnos.

IDA* presenta un comportamiento dependiente de la topología. En Cuello de Botella alcanza 69.00 % de supervivencia y 62.67 turnos de media, mientras que en Laberinto Corporativo disminuye a 38.00 % y aumenta a 86.55 turnos. En Dispersión Abierta obtiene 84.00 % de supervivencia y una media de 49.11 turnos.

DFS presenta un desempeño considerablemente inferior. En Cuello de Botella solo alcanza 11.00 % de supervivencia, mientras que en Laberinto Corporativo y Dispersión Abierta no se registran corridas con tiempo de despeje definido que hayan evacuado agentes.

El algoritmo genético muestra una fuerte dependencia de la topología bajo esta configuración. En Cuello de Botella alcanza 55.00 % de supervivencia, mientras que en Laberinto Corporativo desciende a 1.50 %. En Dispersión Abierta, en cambio, alcanza 80.00 % de supervivencia y una media de 55.80 turnos. Este comportamiento indica que la disponibilidad de alternativas espaciales influye de manera importante en la capacidad de la búsqueda evolutiva para producir trayectorias factibles.

6.2. Resultados con propagación cada cuatro turnos ($k = 4$)

Cuadro 2: Resultados del benchmark con $k = 4$. “Def.” corresponde a corridas con tiempo de despeje definido.

Mapa	Alg.	Sup. (%)	Media	DE	Mín.	Máx.
Cuello	BFS	87.00	53.38	2.82	53	87
	DFS	31.00	152.19	6.27	143	197
	A*	88.00	53.56	3.40	53	85
	IDA*	81.50	63.00	2.39	53	75
	Genético	66.00	82.30	4.64	73	98
Laberinto	BFS	82.00	58.62	3.95	58	94
	DFS	0.50	210.00	0.00	210	210
	A*	82.50	58.42	2.89	58	88
	IDA*	51.50	86.02	0.20	86	88
	Genético	3.00	153.83	5.70	142	160
Dispersión	BFS	91.00	49.24	1.79	49	63
	DFS	0.00	—	—	—	—
	A*	81.50	49.11	1.41	49	67
	IDA*	89.50	49.03	0.33	49	53
	Genético	86.50	55.64	2.77	49	62

Corridas con tiempo definido: Cuello: 174/200, 62/200, 176/200, 163/200 y 132/200; Laberinto: 164/200, 1/200, 165/200, 103/200 y 6/200; Dispersión: 182/200, 0/200, 163/200, 179/200 y 173/200.

Con $k = 4$, las tasas de supervivencia aumentan respecto de $k = 3$ en varias configuraciones. En Cuello de Botella, BFS alcanza 87.00 % y A* 88.00 %, mientras que IDA* alcanza 81.50 %. En Laberinto Corporativo, BFS y A* presentan 82.00 % y 82.50 %, respectivamente. En Dispersión Abierta, BFS alcanza 91.00 % e IDA* 89.50 %.

El algoritmo genético también presenta una diferencia importante según la topología. En Cuello de Botella alcanza 66.00 %, en Laberinto Corporativo solo 3.00 % y en Dispersión Abierta 86.50 %. Por tanto, el aumento de k no produce una mejora uniforme para este algoritmo: el cambio es favorable en Cuello de Botella y Dispersión Abierta, pero su supervivencia sigue siendo muy baja en Laberinto Corporativo.

En términos de turnos de despeje, las búsquedas BFS y A* mantienen medias cercanas entre sí en los tres mapas. En Dispersión Abierta, las medias de los algoritmos BFS, A*, IDA* y genético son 49.24, 49.11, 49.03 y 55.64 turnos, respectivamente. En Laberinto Corporativo se observa una separación mayor, especialmente para IDA* y el algoritmo genético.

6.3. Comparación entre $k = 3$ y $k = 4$

La comparación entre ambas frecuencias de propagación muestra que el comportamiento depende tanto del algoritmo como de la topología. BFS aumenta su supervivencia de 84.00 % a 91.00 % en Dispersión Abierta y de 84.50 % a 87.00 % en Cuello de Botella, mientras que en Laberinto Corporativo pasa de 69.50 % a 82.00 %. A* también mejora en Cuello de Botella y Laberinto Corporativo, y aumenta de 78.50 % a 81.50 % en Dispersión Abierta.

IDA* muestra una mejora especialmente visible en Cuello de Botella, pasando de 69.00 % a 81.50 %, y en Laberinto Corporativo pasa de 38.00 % a 51.50 %. En Dispersión Abierta aumenta de 84.00 % a 89.50 %.

Para el algoritmo genético, la comparación debe considerar que se utiliza una población de 40 individuos y 10 generaciones. Su supervivencia aumenta de 55.00 % a 66.00 % en Cuello de Botella y de 80.00 % a 86.50 % en Dispersión Abierta, mientras que en Laberinto Corporativo aumenta de 1.50 % a 3.00 %.

6.4. Visualización de resultados




Figura 1: Tasa de supervivencia para los seis escenarios experimentales.




Figura 2: Media de turnos de despeje para los seis escenarios experimentales.

6.5. Discusión

Los resultados muestran diferencias asociadas tanto al algoritmo como a la topología del mapa. El hecho de que todos los agentes comiencen desde un mismo punto modifica las condiciones de congestión respecto de una configuración con posiciones iniciales distribuidas. En consecuencia, la comparación actual debe interpretarse como el comportamiento de los algoritmos cuando deben gestionar la evacuación desde una zona inicial común.

BFS y A* presentan tasas de supervivencia relativamente elevadas en las seis configuraciones, con medias de turnos de despeje cercanas entre sí. En particular, sus resultados son consistentes en Dispersión Abierta y Cuello de Botella. En Laberinto Corporativo, ambos mantienen tasas superiores al 69 % con $k = 3$ y superiores al 82 % con $k = 4$.

DFS presenta los resultados más bajos entre las búsquedas evaluadas en varias configuraciones. En Dispersión Abierta no se registraron corridas con tiempo de despeje definido en ninguna de las dos configuraciones de propagación. En Laberinto Corporativo, solo una de las 200 corridas tuvo tiempo de despeje definido con $k = 4$, mientras que con $k = 3$ no hubo ninguna. Esto coincide con sus medias elevadas de turnos cuando sí se produjo despeje.

IDA* presenta una respuesta más variable según el mapa. Su desempeño es alto en Dispersión Abierta y mejora con $k = 4$, alcanzando 89.50 % de supervivencia, pero en Laberinto Corporativo las tasas son considerablemente menores. El límite de 500 nodos puede impedir que algunas búsquedas encuentren una ruta antes de consumir su presupuesto.

El algoritmo genético es el método cuya respuesta depende más de la topología. Con $k = 3$ alcanza 80.00 % en Dispersión Abierta, pero solo 1.50 % en Laberinto Corporativo. Con $k = 4$ alcanza 86.50 % y 3.00 %, respectivamente. En Cuello de Botella presenta un comportamiento intermedio, pasando de 55.00 % a 66.00 %. Esto sugiere que la representación evolutiva y su mecanismo de evaluación se benefician de mapas donde existen varias alternativas espaciales para construir trayectorias.

La configuración actual del algoritmo genético utiliza 40 individuos durante 10 generaciones. La población inicial emplea información de distancia Manhattan para favorecer ciertas acciones, pero la evolución sigue siendo limitada por el número de generaciones y por la aproximación utilizada en la función de fitness. Por ello, los resultados no deben interpretarse como una medida de la calidad óptima que podría alcanzar el algoritmo con un presupuesto evolutivo mayor.

Las modificaciones realizadas al algoritmo genético también incluyen una mutación efectiva, conservación de la mejor ruta factible y un mecanismo de respaldo basado en la memoria de celdas visitadas cuando no se obtiene una ruta factible. Estas medidas buscan reducir ciclos y recorridos repetitivos, pero no eliminan la limitación fundamental de que la función de evaluación no reproduce completamente la evolución futura del fuego ni la interacción simultánea entre todos los agentes.

Las tablas reportan turnos de simulación y no duración de CPU. Por lo tanto, no permiten afirmar que IDA* o el algoritmo genético sean los algoritmos que tardan más en ejecutarse computacionalmente. Además, las diferencias entre configuraciones deben interpretarse considerando la naturaleza estocástica del experimento y el número de corridas con tiempo de despeje definido.

7. Limitaciones y mejoras

Una limitación relevante es que no se fija una semilla global. Esto permite representar la naturaleza estocástica del escenario, pero dificulta reproducir exactamente una ejecución. Para futuros experimentos se podría guardar una semilla por corrida y registrar todos los parámetros utilizados en la propagación del fuego y en la generación de las poblaciones.

La configuración actual establece que todos los agentes comienzan desde un mismo punto. Esta decisión permite estudiar explícitamente situaciones de congestión y competencia por las rutas desde una zona inicial común, pero también limita la generalización de los resultados a escenarios donde los agentes se encuentran distribuidos por el edificio. Una mejora experimental sería comparar sistemáticamente ambos escenarios, manteniendo constantes el mapa, el fuego y el resto de los parámetros.

En IDA*, el límite de 500 nodos constituye una decisión de control experimental. Aumentarlo podría permitir encontrar rutas que actualmente se descartan, pero también incrementaría el costo computacional de algunas búsquedas. Una de las razones para mantener este límite es que algunas ejecuciones podían requerir un tiempo elevado para completar pocas o ninguna iteración.

Para el algoritmo genético, la configuración utilizada considera una población de 40 individuos y 10 generaciones. Este presupuesto limita la cantidad de evolución disponible para mejorar las soluciones. Como mejora, se podría evaluar experimentalmente el efecto de aumentar el número de generaciones o el tamaño de la población, además de ajustar la tasa de mutación y otros parámetros del proceso evolutivo. Estos cambios deberían estudiarse mediante un protocolo controlado para distinguir sus efectos de la variabilidad aleatoria. Y tal vez una mejora mucho más notable sería modificar el código para entrenar el algoritmo antes de ejecutar el benchmark.

Otra mejora importante para el algoritmo genético sería diseñar una función de fitness que incorpore de manera más explícita el riesgo dinámico del fuego. Actualmente, la evaluación constituye una aproximación del entorno, por lo que una trayectoria que parece favorable durante la evaluación puede encontrarse posteriormente con una situación diferente debido a la propagación del fuego y a la interacción entre agentes.

También existe el problema de que la zona protegida para la aparición inicial del fuego no funciona como se espera en mapas cuya salida se encuentra fuera de dicha zona. Una posible mejora sería establecer una zona de protección alrededor de la salida, en lugar de excluir únicamente las últimas filas del mapa. Esto permitiría que la protección se adapte a la geometría de cada escenario.

Finalmente, sería conveniente ampliar las métricas registradas. El benchmark actual utiliza principalmente tasa de supervivencia y turnos de despeje, pero no mide sistemáticamente tiempo de CPU, cantidad de nodos expandidos, número de individuos evaluados ni costo computacional de cada algoritmo. Registrar estas variables permitiría complementar el análisis de efectividad con un análisis de costo computacional.

8. Conclusión

El proyecto implementa los tres paradigmas solicitados: BFS y DFS como búsquedas no informadas, A* e IDA* como búsquedas informadas y un algoritmo genético como método bioinspirado. El sistema integra movimiento ortogonal, espera, capacidad finita, congestión, propagación estocástica del fuego, replanificación y evacuación.

Los resultados obtenidos bajo la configuración actual muestran que el punto de partida común de los agentes modifica el escenario experimental, ya que todos deben comenzar la evacuación desde una misma zona. Esto permite evaluar el efecto de la congestión inicial y de la competencia por las rutas de salida, pero también significa que los resultados deben interpretarse específicamente para este tipo de distribución inicial.

BFS y A* presentan tasas de supervivencia elevadas en las configuraciones evaluadas y mantienen medias de turnos de despeje relativamente cercanas. Con $k = 4$, ambos alcanzan valores superiores al 82 % de supervivencia en Cuello de Botella y Laberinto Corporativo, mientras que BFS alcanza 91.00 % en Dispersión Abierta.

IDA* presenta un comportamiento más dependiente de la topología. En Dispersión Abierta alcanza 84.00 % con $k = 3$ y 89.50 % con $k = 4$, mientras que en Laberinto Corporativo sus tasas son 38.00 % y 51.50 %, respectivamente. Esto muestra que el presupuesto de búsqueda y las restricciones de conectividad pueden tener un efecto importante sobre la capacidad de encontrar rutas antes de alcanzar el límite establecido.

DFS presenta tasas de supervivencia considerablemente menores. En particular, no registra corridas con tiempo de despeje definido en Dispersión Abierta para ninguna de las dos frecuencias de propagación, y presenta resultados muy bajos en Laberinto Corporativo. Sus medias de turnos también son superiores a las observadas para BFS y A* en las configuraciones donde se producen evacuaciones.

El algoritmo genético presenta una fuerte dependencia de la topología. Con una población de 40 individuos y 10 generaciones, alcanza 80.00 % y 86.50 % de supervivencia en Dispersión Abierta para $k = 3$ y $k = 4$, respectivamente. En Cuello de Botella obtiene 55.00 % y 66.00 %, mientras que en Laberinto Corporativo alcanza solo 1.50 % y 3.00 %. Por lo tanto, la configuración evolutiva utilizada logra resultados considerablemente diferentes según la estructura espacial del mapa.

Las modificaciones incorporadas al algoritmo genético, como la mutación efectiva, la conservación de la mejor ruta factible y el mecanismo de respaldo basado en memoria de celdas visitadas, permiten contar con una implementación más elaborada que una versión puramente aleatoria. Sin embargo, la función de fitness sigue siendo una aproximación de un entorno dinámico y el presupuesto de 10 generaciones limita la evolución disponible.

En conjunto, los experimentos muestran que el comportamiento de los algoritmos no depende únicamente del paradigma de búsqueda, sino también de la topología, la frecuencia de propagación del fuego y la distribución inicial de los agentes. Los resultados deben entenderse dentro del protocolo utilizado: 200 simulaciones por combinación, agentes iniciando desde un mismo punto, población genética de 40 individuos durante 10 generaciones, propagación con los parámetros definidos en la implementación, límite de 500 nodos para IDA* y métricas de turnos obtenidas únicamente en las corridas con tiempo de despeje definido.

9. Declaración de uso de IA generativa y procedencia

Gemini, GitHub Copilot y Codex se utilizaron como herramientas de apoyo durante la implementación y documentación. Después de que el autor creara una estructura base del código, algoritmos como BFS, DFS y A*, estas herramientas se utilizaron como apoyo para revisar, modificar y adaptar componentes del código ante cambios, errores y problemas de integración. También se emplearon para la implementación del algoritmo genético y de IDA*, resolver errores específicos, refinar el código, realizar correcciones relacionadas con la complejidad temporal de IDA* y del algoritmo genético, desarrollar la interfaz gráfica, convertir archivos PNG a texto, realizar la lectura de mapas, refactorizar y optimizar el código, mantener la compatibilidad entre cambios y abordar aspectos más complejos de la gestión de eventos para la propagación del fuego.

También se utilizaron como apoyo en la redacción y revisión del informe, incluyendo la corrección de estilo, la corrección ortotipográfica, la estructuración en LaTeX, la organización de ecuaciones y la maquetación de tablas y figuras.

La integración, revisión y adaptación del código al proyecto fueron realizadas por el autor, así como las decisiones sobre parámetros, estructura de clases, integración e inicialización de agentes, estructura de la grilla, funcionamiento del fuego y configuración experimental.

10. GitHub

<https://github.com/LeoRG019/TareaIA1.git>